

要点

- 分布
 1. GPD的依赖分布 $P[X \leq x | X \geq VaR] \sim GPD(VaR, \hat{\xi}, \hat{\sigma} + \hat{\xi}(VaR - u))$
 2. Jarque-Bera Test检验tail的normality,但是数据多很容易reject
- semi-parametric
 - Threshold的选取要尽量大,但区域中shape ξ 需要stable
 - 存在assumption即return必须是i.i.d(经常被violate)
- copula
 1. 计算copula找随机变量关系,再利用单调性回带
 2. 正态copula 没有tail dependence
 3. copula选择需要关注tail拟合
 4. 使用AIC/BIC来选择最优模型
 5. copula不可能是一个点,必定是线

1. 基本概念

收益率

今天减k天前的价格

- 收益率: $R_t = \frac{P_t}{P_{t-k}} - 1 = e^{r_t} - 1$
- 对数收益率: $r_t = \ln \frac{P_t}{P_{t-k}} = \ln(1 + R_t) = \ln P_t - \ln P_{t-k}$
- 分红收益率: $R_t = \frac{P_t + D_t}{P_{t-1}}$
- 对数分红收益率: $r_t = \ln \frac{P_t + D_t}{P_{t-1}}$

VaR

- 相对风险资产(收益率的负分位数): $P[R_t + VaR] = q$
- 风险资产(相对值乘以portfolio大小): 亏损超VaR的概率小于q, $VaR = P_t \cdot VaR_t$

Shortfall Distribution

- 给定亏损分布F,则控制亏损在x和 VaR_q 中的概率:
 $\Theta_q(x) = P[X \leq x | X > VaR_q] = \frac{F(x) - (1-q)}{q}$
- 亏损大于 VaR_q 情况下的期望值: $ES_q = E[X | X > VaR_q] = \frac{1}{q} \int_{x > VaR_q} x f(x) dx$

收益率不同分布下的ES

正态分布	Dexp	GPD
$\mu + \sigma \frac{f(F^{-1}(\alpha))}{\alpha}$	$-\mu + \frac{1 - \ln 2\alpha}{\lambda}$	$VaR_q + \frac{\sigma}{\xi q^\xi} = VaR_q + \frac{\hat{\sigma} + \xi(VaR_q - u)}{1 - \hat{\xi}}$

时间序列数据

- 强平稳: 不同时间分布相同
- 弱平稳: 不同时间方差和均值相同
- 自方差: $COV(y_h) = \frac{1}{n} \sum_{t=1}^{n-h} (y_t - \mu)(y_{t+h} - \mu)$
- 自相关性: $\gamma_h = \frac{COV(y_h)}{\sigma^2}$

概率分布性质

- k 阶中心矩: $\mu_k = E[(X - E[x])^k]$
- 偏度: $\frac{\mu_3}{\mu_2^{3/2}}$
- 峰度: $\frac{\mu_4}{\mu_2^2} - 3$
- 期望 $E(X) = \int x f_X(x) dx$
- 方差 $\sigma^2 = \int (x - E(X))^2 f_X(x) dx$
- Tail probabilities描述当 $x \rightarrow \infty$ 时 $1 - F(x)$ 的变化情况,和指数分布比较:
 $\lim_{x \rightarrow \infty} e^{tx} dF(x) = \infty$ 则 heavy tail

2. 参数估计

Kernel Density Estimate

- 给定若干个离散样本 x_i , 构造平滑分布

$$\hat{f}_b(x) = \frac{1}{n} \sum_{i=1}^n K_b(x - x_i)$$

- K_b : kernel function, 可以是任何 density function, 方差必须是1
- 本质上是样本的平滑分布, b 越大, 越平滑

Semi-parametric Estimation

- 当阈值 u 足够大时, 任何 tail 都可以转化为 GPD:

$$P[X > u + x | X > u] \rightarrow H_\xi(x)$$

- 估计流程
 1. Plot ECDF 分布的 Tail
 2. 使用 shape plot 画出 GPD 的 $\hat{\xi}$ 和 threshold u 的关系
 3. threshold 要尽量大, 但是 shape parameter 要尽量稳定
 4. 通过 Tail plot 检验 threshold 选取的质量
 5. 计算 $\tilde{Va}R_q = GPD^{-1}[1 - \frac{q}{1-ECDF(u)}]$
 6. 基于 GPD 期望的性质, 可以得到 $ES = \tilde{Va}R_q + \frac{\hat{\sigma} + \hat{\xi}(\tilde{Va}R_q - u)}{1 - \hat{\xi}}$

3. Portfolio基本性质

双资产管理

给定双资产组成的 Portfolio $V = n_1 P_1 + n_2 P_2$

- 权重向量 $w = \begin{bmatrix} \frac{n_1 P_1}{n_1 P_1' + n_2 P_2'} & \frac{n_2 P_2}{n_1 P_1' + n_2 P_2'} \end{bmatrix}$
- 收益率 $R = \frac{V'}{V} = \frac{n_1 P_1' + n_2 P_2'}{n_1 P_1 + n_2 P_2}$, 通过 R 来计算 VaR 和 Expected Shortfall
- 对于双资产 Portfolio $V = w R_1 + (1 - w) R_2$, 则通过分散投资不相关资产来最小化风险

$$w = \frac{\sigma_2^2 - \rho_{12} \sigma_1 \sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho_{12} \sigma_1 \sigma_2}$$

Copula模型应用

1. 对每个asset估计marginal distribution \hat{F}_p
2. 使用QQ plot判断 \hat{F}_p 的估计准确度,注意tail
3. 计算asset之间的spearman相关系数
4. 用 \hat{F}_p 生成概率并带入copula模型
5. 绘制copula的等高线,分析估计质量
6. 从copula生成模拟数据,并获得不同权重时的VaR

风险资产模型定义

资产收益率向量	资产收益率期望	收益率协方差矩阵
$R = [R_1 \cdots R_N]^T$	$E[R] = [\mu_1 \cdots \mu_N]^T$	$\text{Cov}(R) = \Sigma$

已知上述条件,找到最合适的权重向量 $W = [w_1 \cdots w_N]^T$ 在收益率最大的情况下最小化风险

- 最小化标准差: $\min w^T \Sigma w$
- 最大化收益率: $w^T \mu = \mu^*$
- 权重和为1: $w^T I = 1$
- 可能还有分散投资,不能做空等附加条件
- 生成的结果为有效边界: 在固定资产的方差 σ 的情况下,可以获得的最大收益 μ

无风险资产混合投资

- 在资产组合中引入了收益率为 μ_f 的无风险资产
- 需要最大化夏普比率:描述了额外收益 $E(R) - \mu_f$ 和风险 σ 的比值,最大化夏普比率等于寻找切线

$$\frac{E(R) - \mu_f}{\sigma}$$

- 令风险资产权重为 w 则有
 - 收益率 $\mu = \mu_f + w(\mu_p - \mu_f)$
 - 方差 $\sigma = w\sigma_p$

最大化夏普比率

- 对于双资产混合无风险模型,令 $v_1 = \mu_1 - \mu_f, v_2 = \mu_2 - \mu_f$,则第一个资产的权重有

$$w_T = \frac{v_1 \sigma_2^2 - v_2 \rho_{12} \sigma_1 \sigma_2}{v_1 \sigma_2^2 + v_2 \sigma_1^2 - (v_1 + v_2) \rho_{12} \sigma_1 \sigma_2}$$

- 在最大化夏普比率的基础上,根据资产模型的方差限制,获得无风险资产的配置

1. 根据 w_T 获得风险资产标准差 σ_T, μ_T
2. 根据给定的风险目标,获得风险资产总占比权重 $w = \frac{\sigma_{target}}{\sigma_T}$
3. 或者根据给定的收益率目标,获得风险资产总占比权重 $w = \frac{\mu_{target} - \mu_f}{\mu_T - \mu_f}$
4. 每个风险资产的比重为 $w \cdot w_T$

4. 单变量分布

正态分布 $N(\mu, \sigma^2)$

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

指数分布 $\text{Exp}(\lambda)$

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

$$F(x) = 1 - e^{-\lambda x}$$

- $\mu = \sigma = \frac{1}{\lambda}$

双指数分布 $\text{Dexp}(\mu, \lambda)$

$$f(x) = \frac{\lambda}{2} e^{-\lambda|x-\mu|}$$

$$F(x) = \begin{cases} \frac{1}{2} e^{-\lambda|x-\mu|} & x < \mu \\ 1 - \frac{1}{2} e^{-\lambda|x-\mu|} & x \geq \mu \end{cases}$$

- $\sigma = \frac{\sqrt{2}}{\lambda}$
- 峰度为3

t分布

- ν 越大, tail越小, 峰度 $\frac{\sigma}{\nu-4}$
- $\sigma = \lambda \sqrt{\frac{\nu}{\nu-2}}$
- $t_\nu(\mu, \lambda^2)$ 是 $Y = \mu + \lambda t_\nu$ 的表示, 标准差不是 λ

Pareto Distribution

$$f(x) = \frac{\alpha \mu^\alpha}{x^{\alpha+1}}$$

$$F(x) = 1 - \frac{\mu^\alpha}{x^\alpha} \quad x \geq \mu$$

GPD(ξ, σ)

- 多项式级的tail

$$f(x) = \frac{1}{\sigma} \left(1 + \frac{\xi(x-\mu)}{\sigma}\right)^{-\frac{1}{\xi}-1}$$

$$F(x) = 1 - \left(1 + \frac{\xi(x-\mu)}{\sigma}\right)^{-\frac{1}{\xi}}$$

GED($\mu, \lambda^2 \nu$)

$$f(x) = \kappa_\nu \exp\left(-\frac{1}{2} \left|\frac{x}{\lambda_\nu}\right|^\nu\right)$$

- ν 越小, tail越heavy
- $\sigma = 1$
- 转换后 $Y = \mu + \lambda X, \sigma = \lambda$

Gamma 分布 $\Gamma(\lambda, \alpha)$

描述了 α 个独立指数分布/Gamma分布的和

- Gamma Function

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx$$
$$f_{\alpha, \lambda}(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

对于正整数 $\alpha, \Gamma(\alpha) = (\alpha - 1)!$

- $\mu = \frac{\alpha}{\lambda}$
- $\sigma = \frac{\sqrt{\alpha}}{\lambda}$
- Gamma分布可加性 $Gamma(\gamma, \alpha_1) + Gamma(\gamma, \alpha_2) = Gamma(\gamma, \alpha_1 + \alpha_2)$

5. 多变量分布

多变量正态分布

参数	随机变量 X	PDF	期望	方差
μ, Σ	p 维向量 X	$f_X(x) = \frac{1}{\sqrt{(2\pi)^p \det \Sigma}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right)$	μ	Σ

多变量T分布

参数	随机变量 X	期望	方差
μ, Λ, ν	$T_n = \mu + \sqrt{\frac{\nu}{W}} X, (X \sim N(0, \Lambda))$ (多变量正态分布除以方差后转换得到)	μ	$\frac{\nu}{\nu-2} \Lambda$

- 所有变量的marginal distribution都是自由度 ν 的T分布,因此tail的性质相同
- 所有变量之间uncorrelated但是dependent,但是当 ν 很大时,可以假设independent

Copulas

定义

- 将随机变量转化到uniform distribution,只考虑他们出现在p-quantile的概率 $U_p = F_{X_p}(X_p)$

$$C(u_1, u_2, \dots, u_p) = P[U_1 \leq u_1, \dots, U_p \leq u_p]$$

$$F_{X_1, \dots, X_p}(x_1, \dots, x_p) = C(F_{X_1}(x_1), \dots, F_{X_p}(x_p))$$

- 通过Copula可以得到变量的联合分布: $f(x, y) = c(F_X(x), F_Y(y)) f_X(x) f_Y(y)$

Copula和相关性

- 对于独立变量 $C(u_1, u_2, \dots, u_p) = \prod_{i=1}^p u_i$
- 对于完全互相依赖的变量, $C(u_1, u_2, \dots, u_p) = \min\{c_i\}$

正态分布 Copula

- 当变量服从联合正态分布的时Copula
- 只和变量之间的相关系数 ρ 有关

$$\frac{1}{2\pi\sqrt{1-\rho^2}} \int_{-\infty}^{F_X^{-1}(u_1)} \int_{-\infty}^{F_Y^{-1}(u_2)} \exp\left(-\frac{1}{2} \frac{s^2 - 2\rho st + t^2}{1-\rho^2}\right) ds dt$$

T-Copuls

- 当变量服从联合T-分布时的Copula
- Copula和 μ 无关,因为不会影响rank

建模流程

1. 估计每个变量的边际分布 \hat{F}_p
2. 回带每个变量的边际分布 \hat{F}_p
3. 获得Copula的表达式估计值 \hat{C}

Archimedean-type Copula定义

- $C(u_1, u_2, \dots, u_p) = \phi^{-1}(\phi(u_1) + \dots + \phi(u_d))$
- ϕ 是严格递减的凸函数
- $\phi(0) = \infty, \phi(1) = 0$
- 通过估计不同模型的 θ 来找到合理的copula分布

Gumbel (logistic Copula)

$$C(u_1, u_2, \dots, u_p) = \exp\left(-\left[(-\log u_1)^\theta + \dots + (-\log u_d)^\theta\right]^{\frac{1}{\theta}}\right)$$

- $\phi(u) = -\log u$
- 适合Heavy tail分布,当 $\theta = 1$ 的时候是独立分布, θ 越大相关性越强

Clayton Copula

$$C(u_1, u_2, \dots, u_p) = (u_1^{-\theta} + \dots + u_d^{-\theta} - d + 1)^{-\frac{1}{\theta}}$$

- $\phi(u) = u^{-\theta} - 1$
- 当 $\theta \rightarrow 0$ 时,变成独立分布

Frank Copula

$$C(u_1, u_2, \dots, u_p) = -\frac{1}{\theta} \log \left(1 + \frac{(e^{-\theta u_1} - 1)(e^{-\theta u_2} - 1)}{\exp(-\theta) - 1} \right)$$

- $\phi(u) = -\ln \frac{\exp(-\theta u) - 1}{\exp(-\theta) - 1}$
- 当 $\theta \rightarrow 0$ 时,变成独立分布