

# 常用公式

---

## 随机变量性质

- 如果  $E(X) = 0$ , 则  $Var(X) = E(X^2)$
- 偏度  $S = \frac{\mu_3}{\sigma^3} = \frac{E(X-E(X))^3}{Var(X)^{3/2}}$
- 峰度  $K = \frac{\mu_4}{\sigma^4} = \frac{E(X^4)}{(Var(X))^2}$

## Beta

- portfolio可以直接把asset的beta按照weight相加
- 收益率相除可以计算  $\mu_R - \mu_f = \beta_R(\mu_M - \mu_f)$
- 风险由两部分组成  $\sigma_i^2 = \beta_i^2 \sigma_M^2 + \sigma_\epsilon^2$

## AR(1)

- 可以从ARCH模型获得, 关注  $\alpha$

$$\gamma(h) = \frac{\sigma^2 \alpha^{|h|}}{1 - \alpha^2}$$
$$\rho(h) = \alpha^{|h|}$$

## MA(q)

- 从0开始

$$\gamma(h) = \sigma^2 \sum_{i=0}^{q-h} \psi_i \psi_{i+h}$$

## ARMA(1,1)

- 可以从GARCH(1,1)模型获得, 关注  $\alpha_1, \beta_1$

$$X_n^2 = \sigma_n^2 \epsilon_n^2 = \sigma_n^2 + V_n = \alpha_0 + \alpha_1 \sigma_{n-1}^2 + \beta_1 X_{n-1}^2 + V_n = \alpha_0 + (\alpha_1 + \beta_1) \sigma_n^2 - \beta_1 V_{n-1} + V_n$$

$$\sigma_{X_n^2} = \frac{1 + \beta_1^2 - 2(\alpha_1 + \beta_1)\beta_1}{1 - (\alpha_1 + \beta_1)^2} \sigma_\epsilon^2$$

$$\rho(h) = (\alpha_1 + \beta_1)^{|h|-1} \frac{\alpha_1 [1 - (\alpha_1 + \beta_1)\beta_1]}{1 + \beta_1^2 - 2(\alpha_1 + \beta_1)\beta_1}$$

## Linear Predictor

- 通常先计算自方差, 然后带入Cov

$$\hat{\alpha} = \Sigma_{YX} \Sigma_X^{-1} = YX^T (XX^T)^{-1} = \frac{\text{Cov}(Y, X)}{\text{Var}(X)}$$

$$MSE = E[(Y - \hat{Y})^2] = \sigma_Y^2 - \frac{\text{Cov}(Y, X)^2}{\text{Var}(X)}$$

# 1. Time Series

---

## 1.1 基本概念

### 不同时间序列定义

- First TS model:  $t_n$  对应  $n \triangle t$  的时间点
- Second-order: 所有  $t_n$  时刻的随机变量  $X_n$  的均值和方差都是有限的

### 平稳性

- 强平稳性: 任意  $h$  个连续是时间序列变量分布相同
- 弱平稳性: 均值相同,  $h$  阶自方差相同

### 特征估计 (只对平稳时间序列有效)

- 均值:  $\hat{\mu} = \frac{1}{N} \sum_{i=1}^N X_i$
- $h$  阶自方差:  $\hat{\gamma}(h) = \frac{1}{N} \sum_{i=1}^{N-h} (X_i - \hat{\mu})(X_{i+h} - \hat{\mu})$
- $h$  阶自相关系数:  $\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)} = \frac{\hat{\gamma}(h)}{\hat{\sigma}^2}$

### 偏自相关系数

- 使用  $X_m$  作为应变量,  $X_{m-1}, \dots, X_{m-h}$  作为自变量, 进行线性回归
- 线性回归得到的参数, 就是 PACF (可以有效去除其他变量的作用)

### Ergodicity

- 当平稳的时间序列 足够长, 均值和自方差的估计值会趋向于真实值
- $\lim_{n \rightarrow \infty} \hat{\mu} = \mu, \lim_{n \rightarrow \infty} \hat{\rho}(h) = \rho(h)$

## 1.2 时间序列检验

### 平稳性检验 Phillips-Perron Test

- 使用 ARMA 拟合数据来进行检验
- $H_0$ : 单位圆内存在单位根, 数据不平稳
- $H_1$ : 数据平稳, 因此 P-value 越小越好

### Jarque-Bera 检验正态分布

- 通过样本的偏度  $S$  和峰度  $K$  来构造参数检验

$$JB = \frac{n}{6} \left( S^2 + \frac{(K-3)^2}{4} \right) \sim \chi_2^2$$

- $H_0$ : 数据服从正态分布,  $JB$  值越偏离  $\chi_2^2$ , 说明样本正态分布的概率越小

### Shapiro-Wilk Test

- 检验样本是否服从假设的正态分布, 分布参数决定  $\alpha_i$
- $W = \frac{(\sum_{i=1}^n \alpha_i x_i)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$

## 2. ARIMA 模型

### 2.1 AR(1)

## 定义

- 给定均值 $\mu$ 和模型参数 $\alpha$ ,时间序列在去除均值之后符合递推式

$$Y_n - \mu = \alpha(X_{n-1} - \mu) + \epsilon_n$$

- $\epsilon_n$ 服从均值 $N(0, \sigma^2)$ 的分布
- $|\alpha| < 1$ ,否则不平稳

## 时序性质

- $\gamma(h) = \frac{\sigma^2 \alpha^{|h|}}{1 - \alpha^2}$
- $\rho(h) = \alpha^{|h|}$

## 参数估计

- 当变量之间服从多元正态分布时,线性回归就是最小化MSE的分布
- 去除均值后给定自变量矩阵 $X \in \mathbb{R}^{d \times m}$ 和应变量矩阵 $Y \in \mathbb{R}^{1 \times m}$ 时,求解 $\alpha^T X = Y$
- $\alpha^T = \Sigma_{YX} \Sigma_X^{-1} = Y X^T (X X^T)^{-1}$
- 使用 $\alpha^T X$ 带入 $\hat{Y}$ 来分析 $MSE = E[(Y - \hat{Y})^2] = \sigma_Y^2 - \Sigma_{YX} \Sigma_X^{-1} \Sigma_{XY}$
- 变量相关性越大,线性回归拟合越准

## 2.2 AR(p)

### 定义

$$Y_n = \phi_1 Y_{n-1} + \phi_2 Y_{n-2} + \cdots + \phi_p Y_{n-p} + \epsilon_n$$

- 系数参数绝对值小于1,则模型平稳

### 参数拟合

- 假定 $Y_t$ 和 $Y_{t-1}, \dots, Y_{t-p}$ 服从多元正态分布,因此可以直接使用线性回归来最小化MSE并估计参数
- 构造自方差矩阵

$$\Sigma_Y = \begin{bmatrix} \gamma(0) & \cdots & \gamma(n-1) \\ \cdots & \cdots & \cdots \\ \gamma(n-1) & \cdots & \gamma(0) \end{bmatrix}$$

- 构造协方差向量

$$\Sigma_{Y_n, Y_{n-p:n-1}} = [\gamma(p), \dots, \gamma(1)]$$

- 可以生成预测模型 $\hat{Y}_t = \Sigma_{Y_n, Y_{n-p:n-1}} \Sigma_Y^{-1} (Y_{n-p:n-1} - \mu) + \mu$

### 矩量法估计参数(Yule-Walker)

- 基于自方差定义,可以得到方程组

$$\gamma(0) = \sum_{i=1}^p \phi_i \gamma(|i|) + \sigma^2$$

$$\gamma(1) = \sum_{i=1}^p \phi_i \gamma(|i-1|)$$

...

$$\gamma(p) = \sum_{i=1}^p \phi_i \gamma(|i-p|)$$

- 带入自方差估计值 $\hat{\gamma}$ 求得 $\sigma$ 和 $\phi_i$

### 线性拟合求参数

- 假定 $Y_t$ 和 $Y_{t-1}, \dots, Y_{t-p}$ 服从多元正态分布,因此可以直接使用线性回归来最小化 $MSE$ 并估计参数
- 构造自方差矩阵

$$\Sigma_Y = \begin{bmatrix} \gamma(0) & \cdots & \gamma(n-1) \\ \cdots & \cdots & \cdots \\ \gamma(n-1) & \cdots & \gamma(0) \end{bmatrix}$$

- 构造协方差向量

$$\Sigma_{Y_n, Y_{n-p:n-1}} = [\gamma(p), \dots, \gamma(1)]$$

- 可以生成预测模型 $\hat{Y}_t = \Sigma_{Y_n, Y_{n-p:n-1}} \Sigma_Y^{-1} (Y_{n-p:n-1} - \mu) + \mu$

### Conditional MLE估计参数

- 对于 $X_p, X_{p-1}, \dots, X_0$ , 有 $X_p^2 - \alpha_0 - \alpha_1 X_{p-1}^2 - \dots - \alpha_p X_0^2 = \epsilon_n \sim N(0, \sigma^2)$ , 因为残差服从独立正态分布, 因此可以计算联合似然函数

$$f(\alpha, \sigma^2 | X) = \prod_{i=p+1}^n \frac{1}{\sqrt{2\pi\sigma}} \exp\left[-\frac{1}{2} \left(\frac{X_i - \sum_{j=1}^p \alpha_j X_{i-j}}{\sigma}\right)^2\right]$$

### 模型选择

- 画残差的QQplot, 是否符合正态分布
- 画残差的ACF, 是否在bound之内
- 对ACF进行Box检验, 确认是否stationary
- 在确保残差正态分布的情况下, 选择AIC最小的模型

## 2.3 MA

### 定义

$$Y_n = \epsilon_n + \psi_1 \epsilon_{n-1} + \dots + \psi_q \epsilon_{n-q}$$

- 使用MA项可以有效拟合时序数据中的自方差

### 时序性质

- $\sigma_Y^2 = \sigma^2 \sum_{i=0}^q \psi_i^2$
- $\gamma(h) = \sigma^2 \sum_{i=0}^{q-h} \psi_i \psi_{i+h}$

## 2.4 ARMA模型

### 模型定义

- AR和MA模型的组合

$$Y_n = \phi_1 Y_{n-1} + \phi_2 Y_{n-2} + \cdots + \phi_p Y_{n-p} + \epsilon_n + \psi_1 \epsilon_{n-1} + \cdots + \psi_q \epsilon_{n-q}$$

- 使用算符简化,如果两边可以消元,这说明可以化简为更简单的ARMA模型:  $\phi(B)Y_n = \psi(B)\epsilon_n$
- 拟合效果往往比单独使用AR或者MA更准确,但是有时候需要去除平均数

### ARMA模型性质

- 方差

$$\sigma_Y^2 = \frac{1 + \sum_{i=1}^q \psi_i^2 + 2 \sum_{i=1}^{\min(p,q)} \psi_i \phi_i}{1 - \sum_{i=1}^p \phi_i^2}$$

## 3. Garch

### 3.1 ARCH模型

#### 定义

- $X_n$ 是误差大小 $\sigma_n$ 和白噪音 $\epsilon_n$ 的乘积  $X_n = \sigma_n \epsilon_n$
- $\epsilon_n \sim N(0, 1)$ , 因此  $E(\epsilon^2) = 1$
- $\sigma_n$ 是时间序列数据, 决定了误差的绝对值  $\sigma_n^2 = \alpha_0 + \sum_{j=1}^p \alpha_j X_{n-j}^2$   $\alpha_0 > 0, \alpha_j \geq 0$
- $\epsilon_n$ 是均值为0, 方差为1的白噪声
- $\alpha_0$ 决定了 $X_n$ 的下界

#### 性质

- 自激发: 当前 $X_n$ 较大时, 之后的 $X_{n+p}$ 都容易较大
- 由于  $\text{Var}(\epsilon_n) = 1$ ,  $E(X_n^2) = E(\sigma_n^2)E(\epsilon_n^2) = [\alpha_0 + \sum_{j=1}^p \alpha_j E(X_{n-j}^2)]$ , 因此期望符合 $p$ 阶的AR模型

#### 参数估计

- MLE估计太困难, 因此使用condition MLE来估计 $\alpha_j$ 的值
- 对于  $X_n = \sqrt{\alpha_0 + \sum_{i=1}^p \alpha_i X_{n-i}^2} \epsilon_n$ , 服从均值为0, 方差为 $\alpha_0 + \sum_{i=1}^p \alpha_i X_{n-i}^2$ 的正态分布, 因此可以用来计算似然函数, 并对参数进行估计

$$L(\alpha_0, \alpha_1 | x) = -\frac{1}{2} \sum_{j=p+1}^n \log[2\pi(\alpha_0 + \sum_{i=1}^p \alpha_i X_{j-i}^2)] - \frac{1}{2} \sum_{j=p+1}^n \frac{X_j^2}{\alpha_0 + \sum_{i=1}^p \alpha_i X_{j-i}^2}$$

- 通过最大化所有项的 $f$ 可以得到对 $\alpha$ 的估计值

### 3.2 GARCH模型

#### 定义

- 给 $X_n$ 添加了均值,  $X_n = \mu_n + \sigma_n \epsilon_n$
- 误差绝对值由之前的两项组成

$$\sigma_n^2 = \alpha_0 + \sum_{i=1}^p \beta_i \sigma_{n-i}^2 + \sum_{j=1}^q \alpha_j (X_{n-j} - \mu_{n-j})^2$$

### Garch(1,1)

- 实际应用最常见,且通常先去除均值 $\mu$
- Garch(1,1)中 $X_n^2$ 服从ARMA(1,1)模型,且残差是 $V_n = \sigma_n^2(\epsilon_n^2 - 1)$ 的白噪声, $\alpha_1 + \beta_1$ 是会决定波动率性质

$$X_n^2 = \sigma_n^2 \epsilon_n^2 = \sigma_n^2 + V_n = \alpha_0 + \alpha_1 \sigma_{n-1}^2 + \beta_1 X_{n-1}^2 + V_n = \alpha_0 + (\alpha_1 + \beta_1) \sigma_{n-1}^2 - \beta_1 V_{n-1} + V_n$$

$$\sigma_{X_n^2} = \frac{1 + \beta_1^2 - 2(\alpha_1 + \beta_1)\beta_1}{1 - (\alpha_1 + \beta_1)^2} \sigma_\epsilon^2$$

$$\rho(h) = (\alpha_1 + \beta_1)^{|h|-1} \frac{\alpha_1[1 - (\alpha_1 + \beta_1)\beta_1]}{1 + \beta_1^2 - 2(\alpha_1 + \beta_1)\beta_1}$$

- 当时间序列趋向于无穷时,方差会收敛于特定值

$$\sigma_\infty^2 \rightarrow \frac{\alpha_0}{1 - \alpha_1 - \beta_1} (\alpha_1 + \beta_1 < 1)$$

- 给定 $n$ 时刻的 $\sigma$ ,则可以估计 $h$ 时刻后的 $\sigma_{n+h}$ 期望 ( $\alpha_1 + \beta_1$ )决定了偏向 $\sigma_n^2$ 还是 $\sigma_\infty^2$

$$E(\sigma_{n+h}^2 | \sigma_{1:n}) = \sigma_\infty^2 + (\alpha_1 + \beta_1)[E(\sigma_{n+h-1}^2) - \sigma_\infty^2] = (\alpha_1 + \beta_1)^{h-1} \sigma_n^2 + [1 - (\alpha_1 + \beta_1)^{h-1}] \sigma_\infty^2$$

### Half-Life of Volatility

- 波动率之差恢复到之前一半的耗时 $k$

$$|E(\sigma_{n+k}^2 | \sigma_{1:n}) - \sigma_\infty^2| \leq \frac{1}{2} |\sigma_{n+1}^2 - \sigma_\infty^2|$$

- 对于Garch(1,1),可以通过带入预测式求解 $(\alpha_1 + \beta_1)^{k-1} \leq \frac{1}{2}$
- $\alpha_1 + \beta_1$ 越大,说明作用持续时间越久,衰减期越长

## 3.3 GARCH模型变种

### 结合ARMA模型生成的综合模型

- 观测值服从ARMA模型 $X_n = \sum_{i=1}^p \psi_i X_{n-i} + \sum_{j=1}^q \phi_j \epsilon_{n-j} + \epsilon_n$  (通常只有AR部分)
- 残差波动服从Garch模型 $\epsilon_n = \sigma_n \delta_n, \sigma_n^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \sigma_{n-i}^2 + \sum_{j=1}^q \beta_j \epsilon_{n-j}^2$
- 分步估计法: 先用ARMA模型拟合,再用Garch模型拟合残差,结果可能不准确,但泛化能力更强
- 联合估计法: 直接估计所有参数,理论上更准确,但结果鲁棒性不强

### APARCH Model

- 模型定义

$$\sigma_t^\delta = \alpha_0 + \sum_{i=1}^p \alpha_i (|X_{t-i}| - \gamma_i X_{t-i})^\delta + \sum_{j=1}^q \beta_j \sigma_{t-j}^\delta$$

- $\delta$ : power parameter,决定了波动率的幂,对于GARCH来说是2
- $\gamma$ : leverage parameter,决定了模型的不对称性,对于GARCH来说是0

## 4. Stochastic Volatility

## 4.1 模型定义

### 特点

- 波动率是随机的,和表现出来的收益率无关,即 $\sigma$ 不会再由 $X$ 决定
- 通常使用马隐模型中的隐状态和显状态来描述模型
- 使用MCMC采样来获得模型的似然函数

### 优点

- 可以描述更多更复杂的波动率表现
- 估计准确度高,似然函数大

### 缺点

- 参数更多,模型更复杂,稳定性可能不好
- 计算困难,没有直接计算似然函数的方式

## 4.2 The Volatility Model

### 定义

- $X_n$ 符合AR过程

$$X_n = \alpha_0 + \sum_{i=1}^p \alpha_i X_{n-i} + \epsilon_n$$

- 残差(白噪音)的波动率服从SV模型

$$\epsilon = \sqrt{h_n} \delta_n \quad \delta_n \sim N(0, 1)$$

$$\log(h_n) = \beta_0 + \sum_{i=1}^p \phi_i \log(h_{n-i}) + \sum_{j=1}^q \psi_j \nu_{n-j} + \nu_n$$

### 性质

- $h_n$ 的对数服从ARMA(p,q)模型
- $h_n$ 不再由 $X_{n-1}$ 或者 $\epsilon_{n-1}$ 决定,而是使用新的独立随机项

## 5. Arbitrage

### 5.1 Basic Idea

#### Assumption

- 找到价格平稳的资产组合
- 当价格过高或者过低时,根据均值回归,存在套利机会
- 有限时间内,总可以找到做空或者做多的机会

#### 风险

- 基本面风险: 当公司发生基本面变化时,价格不再平稳
- 流动性风险: 当发现套利机会时,却无法成交,或者成交成本很高
- 噪音风险: 可能因为散户等因素影响,导致套利逻辑失效
- 执行风险: 套利可能无法完美执行,受到交易时间差,滑点等因素影响

## 5.2 资产间套利(Co-Integration)

### 双资产套利

- 对于时间序列 $Y_1$ 和 $Y_2$ ,可以找到 $\lambda$ 使得 $Y_1 - \lambda Y_2$ 是平稳的
- 使用线性回归找到 $\lambda$ ,再通过Phillips-Ouliaris检验平稳性

### 多资产套利

- 给定 $d$ 个资产 $Y_t = [Y_{1,t} \ Y_{2,t} \ \cdots \ Y_{d,t}]$
- 找到分配矩阵 $A \in \mathbb{R}^{r \times d}$ 使得 $X_t = AY_t^T$ 是平稳的
- 即矩阵自方差(Cross Auto Covariance)  $\text{Cov}(X_t, X_{t+h})$ 只由 $h$ 决定

## 6. Portfolio Management

### 6.1 Portfolio基本性质

#### 双资产管理

给定双资产组成的Portfolio  $V = n_1 P_1 + n_2 P_2$

- 权重向量 $w = \begin{bmatrix} \frac{n_1 P_1}{n_1 P_1' + n_2 P_2'} & \frac{n_2 P_2}{n_1 P_1' + n_2 P_2'} \end{bmatrix}$
- 收益率 $R = \frac{V'}{V} = \frac{n_1 P_1' + n_2 P_2'}{n_1 P_1 + n_2 P_2}$ ,通过 $R$ 来计算 $VaR$ 和Expected Shortfall
- 对于双资产Portfolio  $V = wR_1 + (1 - w)R_2$ ,则通过分散投资不相关资产来最小化风险

$$w = \frac{\sigma_2^2 - \rho_{12}\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho_{12}\sigma_1\sigma_2}$$

#### Copula模型应用

- 对每个asset估计marginal distribution  $\hat{F}_P$
- 使用QQ plot判断 $\hat{F}_P$ 的估计准确度,注意tail
- 计算asset之间的spearman相关系数
- 用 $\hat{F}_P$ 生成概率并带入copula模型
- 绘制copula的等高线,分析估计质量
- 从copula生成模拟数据,并获得不同权重时的 $VaR$

### 6.2 风险资产模型

#### 定义

资产收益率向量	资产收益率期望	收益率协方差矩阵
$R = [R_1 \cdots R_N]^T$	$E[R] = [\mu_1 \cdots \mu_N]^T$	$\text{Cov}(R) = \Sigma$

已知上述条件,找到最合适的权重向量 $W = [w_1 \cdots w_N]^T$ 在收益率最大的情况下最小化风险

- 最小化标准差:  $\min w^T \Sigma w$
- 最大化收益率:  $w^T \mu = \mu^*$
- 权重和为1:  $w^T I = 1$
- 可能还有分散投资,不能做空等附加条件
- 生成的结果为有效边界: 在固定资产的方差 $\sigma$ 的情况下,可以获得的最大收益 $\mu$



## 风险资产收益率/方差估计

- 使用经验数据对资产间的收益率和协方差进行估计,但是会引入bias
- 使用Bootstrap对样本收益率,方差和最优夏普率进行估计,置信区间是 $[2\hat{\theta} - q_U, 2\hat{\theta} - q_L]$

## 6.3 模型最优化

### 无风险资产混合投资

- 在资产组合中引入了收益率为 $\mu_f$ 的无风险资产
- 需要最大化夏普比率:描述了额外收益 $E(R) - \mu_f$ 和风险 $\sigma$ 的比值,最大化夏普比率等于寻找切线

$$\frac{E(R) - \mu_f}{\sigma}$$

- 令风险资产权重为 $w$ 则有
  - 收益率 $\mu = \mu_f + w(\mu_p - \mu_f)$
  - 方差 $\sigma = w\sigma_p$

### 最大化Portfolio夏普比率流程

1. 根据无风险资产收益率 $\mu_f$ ,最大化风险资产的夏普比率

$$w_T = \frac{v_1\sigma_2^2 - v_2\rho_{12}\sigma_1\sigma_2}{v_1\sigma_2^2 + v_2\sigma_1^2 - (v_1 + v_2)\rho_{12}\sigma_1\sigma_2} \quad (v_1 = \mu_1 - \mu_f, v_2 = \mu_2 - \mu_f)$$

2. 根据 $w_T$ 获得风险资产标准差 $\sigma_T, \mu_T$

3. 根据给定的风险/收益率约束,获得风险资产占比

- 给定风险约束,则风险资产总占比权重  $w = \frac{\sigma_{target}}{\sigma_T}$
- 给定收益率目标,则获得风险资产总占比权重  $w = \frac{\mu_{target} - \mu_f}{\mu_T - \mu_f}$

4. 每个风险资产的比重为 $w \cdot w_T$

## 6.4 混合资产定价模型 (CAPM)

### Capital Market Line(CML)

- 通过无风险收益率和波动率描述资产收益率
- 说明了夏普率相等,即增加风险资产配比时,超额收益永远和风险成正比

$$\mu_R = \mu_f + \frac{\mu_M - \mu_f}{\sigma_M} \sigma_R \Leftrightarrow \frac{\mu_M - \mu_f}{\sigma_M} = \frac{\mu_R - \mu_f}{\sigma_R}$$

- 给定 $\text{VaR}_q$ 和收益率 $\mu_m$ 的 $q$ 分位数获得配比资产 $w$

$$P((1-w)\mu_f + w\mu_m \leq -\tilde{\text{VaR}}_q) = q$$

$$P(\mu_m \leq \frac{(w-1)\mu_f - \tilde{\text{VaR}}_q}{w}) = q$$

$$w = \frac{\tilde{\text{VaR}}_q + \mu_f}{\mu_f - \Phi_q}$$

## $\beta$ 和Security Market Line (SML)

- 对于任意资产, $\beta_R$ 的定义和估计值分别有

$$\beta_R = \frac{\text{Cov}(R, R_M)}{\sigma_M^2}$$

- 通过 $\beta$ 可以给任意资产定义Security Market Line:  $\mu_R - \mu_f = \beta_R(\mu_M - \mu_f)$
- 通过对数据做线性回归,可以估计 $\hat{\beta}_R$ ,并带入到SML中估计收益率

$$\hat{\beta}_R = \frac{\sum_{t=1}^T (R_t - \bar{R})(R_{Mt} - \bar{R}_M)}{\sum_{t=1}^T (R_{Mt} - \bar{R}_M)^2}$$

- 和1做对比 $\beta_R$ 越大,则风险越高

## 资产收益率拟合

- 通过线性回归,可以对*i*资产收益率进行拟合

$$\mu_i - \mu_f = \alpha_i + \beta_i(\mu_m - \mu_f) + \epsilon_i$$

- 在CAPM假设成立的情况下, $\alpha_i$ 应该为0,如果 $\alpha_i$ 大于0,则说明 $\mu_i$ 被低估了
- 通过分析 $\beta_i$ 的 $R^2$ ,可以验证收益率的来源是市场还是误差

## 6.5 风险分析

### 风险计算

- 对于资产*i*,则有 $\sigma_i^2 = \beta_i^2 \sigma_M^2 + \sigma_\epsilon^2$ 
  - 市场系统性风险:  $\beta_i^2 \sigma_M^2$ ,可以通过对冲减少
  - 非市场风险:  $\sigma_\epsilon^2$ ,可以通过分散投资减少
- 对于市场协方差,则有 $\sigma_{iM} = \beta_i \sigma_M^2$
- 对于任意资产*i, j*则有 $\sigma_{ij} = \beta_i \beta_j \sigma_M^2$

### Portfolio风险

- 给定权重为*w*的portfolio,则可以重新计算风险
- $\beta_P = \sum_{i=1}^N w_i \beta_i$
- 通过分散投资减少非市场风险:  $\epsilon_P = \sum_{i=1}^N w_i \epsilon_i$

## 6.6 三因子模型

### 模型定义

- 通过添加其他参数作为回归项,来解释标的的收益率

$$\mu_i - \mu_f = \alpha_i + \beta_{i1}(\mu_m - \mu_f) + \beta_{i2} \cdot \text{SMB} + \beta_{i3} \cdot \text{HML} + \epsilon_i$$

- SMB: 小市值公司收益率更高
- HML: 低市净率的公司收益率更高

### 计算流程

- 根据流通市值,将标的分成1:1的大市值(B)和小市值(S)组
- 根据BM(市净率倒数)数据将标的按照3:4:3分成(H/M/L)三组
- 通过市值加权计算每组中的平均收益率

#### 4. 通过收益率计算因子

- $\text{SMB} = \frac{1}{3}(\mu_{SL} + \mu_{SM} + \mu_{SH}) - \frac{1}{3}(\mu_{BL} + \mu_{BM} + \mu_{BH})$
- $\text{HML} = \frac{1}{2}(\mu_{SH} + \mu_{BH}) - \frac{1}{2}(\mu_{SL} + \mu_{BL})$